

Matriz de Costos y Decisión

Selección de modelos por tarea y ahorro estimado

Documento	Proyecto	Fecha
Matriz de Costos y Decisión	Ecosistema IA Autónomo para Atención de Clientes	26/08/2026

Alcance

Documento construido a partir de los workflows y estructuras implementadas. Las limitaciones o componentes no implementados se identifican expresamente.

1. Decisión de modelo

Tarea	Opción	Precio entrada USD/1M	Precio salida USD/1M	Decisión
Clasificar correo y redactar respuesta breve	GPT-4o mini	0,15	0,60	Modelo implementado; adecuado para tareas focalizadas y JSON estructurado.
Lectura densa o análisis complejo	Claude Sonnet 5	2,00	10,00	Referencia comparativa; no implementado en el workflow.
Alternativa Claude ligera	Claude Haiku 4.5	1,00	5,00	Referencia comparativa; no implementado.
Procesamiento masivo no urgente	Batch API	GPT-4o mini: 0,075	GPT-4o mini: 0,30	Propuesta para lotes; no implementada en el workflow actual.

Decisión final

El workflow utiliza GPT-4o mini porque la tarea es breve, focalizada y exige salida JSON. Claude y Batch se incluyen como alternativas de decisión, no como componentes implementados.

2. Ahorro estimado

Supuesto de comparación: 1.000 correos mensuales, 500 tokens de entrada y 150 tokens de salida por correo. El cálculo se limita al coste de tokens; no incluye n8n, Airtable, Gmail, impuestos ni costes de infraestructura.

Modalidad	Entrada	Salida	Coste mensual estimado
GPT-4o mini estándar	0,5 M x 0,15 = USD 0,075	0,15 M x 0,60 = USD 0,090	USD 0,165
GPT-4o mini Batch	0,5 M x 0,075 = USD 0,0375	0,15 M x 0,30 = USD 0,045	USD 0,0825
Claude Sonnet 5 estándar	0,5 M x 2,00 = USD 1,00	0,15 M x 10,00 = USD 1,50	USD 2,50

Resultado

Para el supuesto indicado, Batch reduciría el coste de GPT-4o mini de USD 0,165 a USD 0,0825: ahorro estimado de USD 0,0825, equivalente al 50%. Batch solo se recomienda cuando la respuesta no debe ser inmediata.

3. Reglas de optimización

- Usar GPT-4o mini para clasificación, prioridad y respuesta breve.
- Enviar solo el mensaje necesario; excluir firmas, adjuntos y cadenas extensas.
- Exigir salida JSON compacta.
- Limitar la salida en el nodo de IA cuando la configuración lo permita.

- No reprocesar el mismo correo_id.
- Reservar Batch para reclasificaciones históricas o procesos masivos no urgentes.

4. Fuentes de precios

- OpenAI, GPT-4o mini: USD 0,15 por 1M tokens de entrada y USD 0,60 por 1M tokens de salida.
- OpenAI, GPT-4o mini Batch: USD 0,075 entrada y USD 0,30 salida por 1M tokens.
- Anthropic, Claude Sonnet 5: USD 2 entrada y USD 10 salida por 1M tokens.
- Anthropic, Claude Haiku 4.5: USD 1 entrada y USD 5 salida por 1M tokens.

Enlaces de referencia: developers.openai.com/api/docs/models/gpt-4o-mini y platform.claude.com/docs/en/about-claude/pricing