

Matriz de Costes y Decisión

Selección de modelos por tarea y ahorro estimado

Documento	Proyecto	Fecha
Matriz de Costes y Decisión	Ecosistema IA Autónomo para Atención de Clientes	27/08/2026

Alcance

Documento combinado a partir de la matriz aportada y la matriz técnica elaborada para el workflow. Se distingue expresamente entre el modelo implementado y las alternativas de comparación.

1. Decisión de modelo

Tarea	Opción	Entrada USD/1M	Salida USD/1M	Decisión
Clasificar correo, asignar prioridad y redactar respuesta breve	GPT-4o mini	0,15	0,60	Implementado. Adecuado para una tarea focalizada que exige JSON estructurado.
Lectura densa o análisis complejo	Claude Sonnet 5	2,00	10,00	Referencia comparativa; no implementado en el workflow.
Alternativa Claude ligera	Claude Haiku 4.5	1,00	5,00	Referencia comparativa; no implementado.
Procesamiento masivo no urgente	GPT-4o mini Batch	0,075	0,30	Alternativa para lotes; no implementada en el workflow actual.
Modelo OpenAI de mayor coste	GPT-4o	2,50	10,00	Referencia comparativa dentro del mismo proveedor; no implementado.

Decisión final

El workflow utiliza GPT-4o mini porque la tarea real es breve, focalizada y exige una salida JSON con categoria_ia, prioridad_ia y respuesta_ia. Claude, Batch y GPT-4o se presentan como alternativas de decisión, no como componentes implementados.

2. Precios de referencia

Los valores se expresan en dólares estadounidenses por un millón de tokens. Los precios de GPT-4o mini y GPT-4o se basan en documentación oficial de OpenAI. Los precios de Claude Sonnet 5 y Claude Haiku 4.5 se basan en documentación oficial de Anthropic. Los precios pueden cambiar y deben verificarse antes de un uso productivo.

Modelo / modalidad	Entrada	Salida	Estado en el proyecto
GPT-4o mini estándar	USD 0,15	USD 0,60	Implementado
GPT-4o mini Batch	USD 0,075	USD 0,30	No implementado
GPT-4o estándar	USD 2,50	USD 10,00	No implementado
Claude Sonnet 5	USD 2,00	USD 10,00	No implementado
Claude Haiku 4.5	USD 1,00	USD 5,00	No implementado

3. Supuesto de comparación

Escenario hipotético, no consumo real: 1.000 correos mensuales, 500 tokens de entrada y 150 tokens de salida por correo. Total mensual: 0,5 millones de tokens de entrada y 0,15 millones de tokens de salida. El cálculo incluye únicamente tokens del modelo; excluye n8n, Airtable, Gmail, impuestos e infraestructura.

4. Coste mensual estimado

Modalidad	Cálculo de entrada	Cálculo de salida	Coste mensual
GPT-4o mini estándar	$0,5 \times 0,15 = \text{USD } 0,075$	$0,15 \times 0,60 = \text{USD } 0,090$	USD 0,165
GPT-4o mini Batch	$0,5 \times 0,075 = \text{USD } 0,0375$	$0,15 \times 0,30 = \text{USD } 0,045$	USD 0,0825
GPT-4o estándar	$0,5 \times 2,50 = \text{USD } 1,25$	$0,15 \times 10,00 = \text{USD } 1,50$	USD 2,75
Claude Sonnet 5	$0,5 \times 2,00 = \text{USD } 1,00$	$0,15 \times 10,00 = \text{USD } 1,50$	USD 2,50
Claude Haiku 4.5	$0,5 \times 1,00 = \text{USD } 0,50$	$0,15 \times 5,00 = \text{USD } 0,75$	USD 1,25

5. Ahorro estimado

Comparación	Ahorro en el supuesto	Interpretación
Batch frente a GPT-4o mini estándar	USD 0,0825 al mes; 50%	Ahorro teórico si la respuesta puede procesarse de forma diferida.
GPT-4o mini frente a GPT-4o	USD 2,585 al mes; 94% aprox.	Ahorro teórico del modelo implementado frente a GPT-4o.
GPT-4o mini frente a Claude Sonnet 5	USD 2,335 al mes; 93,4%	Comparación teórica; Claude no está implementado.
GPT-4o mini frente a Claude Haiku 4.5	USD 1,085 al mes; 86,8%	Comparación teórica; Claude no está implementado.

Resultado principal
En el escenario supuesto, GPT-4o mini estándar tendría un coste estimado de USD 0,165 al mes. La modalidad Batch reduciría ese coste a USD 0,0825, equivalente a un ahorro teórico del 50%. Batch solo se recomienda cuando la respuesta no debe ser inmediata.

6. Reglas de optimización

- Usar GPT-4o mini para clasificación, prioridad y respuesta breve.
- Enviar únicamente el asunto y el contenido necesario; excluir firmas, adjuntos y cadenas extensas.
- Exigir una salida JSON compacta.
- Limitar la longitud de salida cuando la configuración del nodo lo permita.
- Mantener una sola llamada al modelo por correo.
- Usar el filtro de correos no leídos y Mark a message as read para evitar reprocesamientos.
- Reservar Batch para reclasificaciones históricas o procesos masivos no urgentes.

7. Lectura correcta de la matriz

La matriz no afirma que Claude, GPT-4o o Batch estén integrados. Su función es justificar la selección del modelo implementado mediante una comparación de precios y usos posibles. Los importes mensuales son estimaciones calculadas sobre un volumen hipotético, no datos de facturación real.

8. Fuentes oficiales

OpenAI, GPT-4o mini:

<https://developers.openai.com/api/docs/models/gpt-4o-mini>

OpenAI, precios de API:

<https://developers.openai.com/api/docs/pricing>

Anthropic, precios de Claude:

<https://platform.claude.com/docs/en/about-claude/pricing>

Documento elaborado con precios verificados el 27/08/2026.